

PRÁCTICO 3 TEORÍA DE LA INFORMACIÓN: “Compactadores”

1. Sean los siguientes códigos:

s	p _i	a	b	c	d	e	f
s ₁	1/2	000	0	0	0	0	0
s ₂	1/4	001	01	10	10	10	100
s ₃	1/16	010	011	110	110	1100	101
s ₄	1/16	011	0111	1110	1110	1101	110
s ₅	1/16	100	01111	11110	1011	1110	111
s ₆	1/16	101	011111	111110	1101	1111	001

a. Clasificar cada uno de ellos (Bloque, No singular, Instantáneos, Unívocamente decodif.)

Código	Bloque o no bloque	Singular o no singular	unívocamente decodificable	instantáneo o no instantáneo
a	bloque	no singular	univ decodif	instantáneo
b	no bloque	no singular	univ decodif	no instantáneo
c	no bloque	no singular	univ decodif	instantáneo
d	no bloque	no singular	no univ decodif	-
e	no bloque	no singular	univ decodif	instantáneo
f	no bloque	no singular	no univ decodif	-

b. Calcular la longitud promedio de los unívocamente decodificables.

$$\bar{L} = \sum_{i=1}^q p_i \cdot l_i$$

Long a = $\frac{1}{2} \cdot 3 + \frac{1}{4} \cdot 3 + \frac{1}{16} \cdot 3 + \frac{1}{16} \cdot 3 + \frac{1}{16} \cdot 3 + \frac{1}{16} \cdot 3 = 3$ bits/símbolo

Long b= 2.125 bits/símbolo

long c= 2.125 bits/símbolo

long e= 2 bits/símbolo

c. En los códigos que presenten problemas, indicar qué falla y proponer una modificación mínima.

Los códigos que fallan son el d y el f, ambos son no unívocamente decodificable, es decir que un mensaje puede ser interpretado de formas distintas generando ambigüedades. Aplicamos las siguientes modificaciones:

d	d modificado	f	f modificado
0	0	0	000
10	10	100	100
110	110	101	101
1110	1110	110	110
1011	11110	111	111
1101	111110	001	0010

2. Ejercicios

a. ¿Cuál de los conjuntos de longitudes de la siguiente tabla es válida para un código unívocamente decodificable con base $X\{0,1,2\}$?

$$\sum_{i=1}^q r^{-l_i} \leq 1$$

Desigualdad de kraft

$r=3$

Código A: $2(3^{-1}) + 1(3^{-2}) + 2(3^{-3}) + 1(3^{-4}) + 4(3^{-5}) = 0.8807$ **VÁLIDO.**

Código B: $2(3^{-1}) + 2(3^{-2}) + 2(3^{-3}) + 3(3^{-4}) + 1(3^{-5}) = 1.0041 > 1$ **INVÁLIDO.**

Código C: $1(3^{-1}) + 4(3^{-2}) + 6(3^{-3}) = 1 \leq 1$ **VÁLIDO (Completo).**

Código D: $2(3^{-1}) + 2(3^{-2}) + 2(3^{-3}) + 2(3^{-4}) + 3(3^{-5}) = 1 \leq 1$ **VÁLIDO (Completo).**

b. Construir un código instantáneo con cada conjunto de longitudes válidas

longitud	código A	código C	código D
1	0 - 1	0	0 - 1
2	20	10 - 11 - 12 - 20	20 - 21
3	210 - 211	210 - 211 - 212 - 220 - 221 -222	220 - 221
4	2120		2220 - 2221

5	21210 -21211 - 21212 - 21220		22220 - 22221 - 22222
---	---------------------------------	--	--------------------------

Long. palabra →	1	2	3	4	5
Código A	2	1	2	1	4
Código B	2	2	2	3	1
Código C	1	4	6	0	0
Código D	2	2	2	2	3

3. Demostrar que el código coma cumple Kraft

Para un código coma r -ario de q símbolos con longitudes $l_i = i$ (para $i = 1, \dots, q-1$) y $l_q = q-1$:


$$\sum_{i=1}^{q-1} r^{-i} + r^{-(q-1)} = r^{-(q-1)} + \sum_{i=1}^{q-1} r^{-i}$$

Para la base binaria ($r = 2$):

$$\frac{1}{2} + \frac{1}{4} + \dots + \frac{1}{2^{q-2}} + \frac{1}{2^{q-1}} + \frac{1}{2^{q-1}} = 1$$

Como la suma es exactamente $1 \leq 1$, se demuestra que todo código coma cumple estrictamente la Desigualdad de Kraft ⁴.

4. Sea un código trinario. Codificar los diez dígitos decimales con longitudes 1, 2, 2, 2, 2, 3, 3, 3,3. Si no se pudiera ¿hasta cuantos dígitos podría codificar?, Realice el árbol de codificación



5. Entropía y codificación estadística: Sea la prob. de la fuente: A= 0.30, B=0.25, C=0.18, D=0.12, E=0.08, F=0.07

a. Calcular la entropía $H(x)$

$$H(X) = - \sum p_i \log_2(p_i) = 2.3935 \text{ bits/símbolo}$$

b. Construir los códigos de Shannon, Fano y Huffman

c. Calcular para cada método la longitud promedio L , la eficiencia $\eta = H(X)/L$ y la redundancia $R=1-\eta$

d. Comparar los resultados y justificar cuál se aproxima mejor al límite teórico.

b)

$$L_i = \log_2 \frac{1}{p_i}$$

Formula de Shannon

Símbolo	p	L_i	FA	FA base 2	Código
A	0,30	2	0	0,0000	00
B	0,25	2	0,30	0,01001100	01
C	0,18	3	0,53	0,10001100	100
D	0,12	4	0,73	0,10111010	1011
E	0,08	4	0,86	0,11011001	1101
F	0,07	4	0,93	0,11101110	1110

Formula de Fano

A	0,30	1	0	A = 10
B	0,25	1 <th>1</th> <td>B = 11</td>	1	B = 11
C	0,18	0 <th>0</th> <td>C = 00</td>	0	C = 00
D	0,12	0 <th>1</th> <td>D = 010</td>	1	D = 010
E	0,08	1 <th>1</th> <td>E = 0110</td>	1	E = 0110
F	0,07	1 <th>1</th> <td>F = 0111</td>	1	F = 0111

Formula de Huffman

A	0,3000	0,3000	0,3000	0,431	0,57	0
B	0,2510	0,2510	0,2501	0,3000	0,43	1
C	0,1811	0,1811	0,1520	0,27	0,01	
D	0,12011	0,152010	0,18	0,11		
E	0,080101	0,12011				
F	0,070100	0,100				

c)

Long Shannon = $\sum L_i \cdot p_i = 2,72$ $\eta = 0,88$ $R = 0,12$

Long Fano = 2,42 $\eta = 0,99$ $R = 0,01$

Long Huffman = 2,42 $\eta = 0,99$ $R = 0,01$

d) Dado los resultados Huffman y Fano se aproximan optimamente al límite teórico $H(X)$ minimizando la longitud promedio ($L = 2,42$).

6. Método de diccionario: LZ y LZW. Trabajar con la cadena:

ERRECONERRECIGARROERRECONERREBARRIL

a. Aplicar LZ utilizando una ventana de búsqueda de 6 símbolos y una ventana de anticipación de 4 símbolos. Mostrar las tuplas generadas y reconstruir la cadena

S/C= Sin Coincidencia

Pas o	Buffer de Busqueda	Buffer de mirar mas alla	Coinciden- cia hacia atras	Salida	Salida Reconstruida
1	(vacio)	ERRE	S/C	(0,0,'E')	E
2	E	RREC	S/C	(0,0,'R')	ER
3	ER	RECO	R	(1,1,'E')	ERRE
4	ERRE	CONE	S/C	(0,0,'C')	ERREC
5	ERREC	ONER	S/C	(0,0,'O')	ERRECO
6	ERRECO	NERR	S/C	(0,0,'N')	ERRECON
7	RRECON	ERRE	E	(4,1,'R')	ERRECONER
8	ECONER	RECI	R	(1,1,'E')	ERRECONERRE
9	ONERRE	CIGA	S/C	(0,0,'C')	ERRECONERREC
10	NERREC	IGAR	S/C	(0,0,'I')	ERRECONERRECI
11	ERRECI	GARR	S/C	(0,0,'G')	ERRECONERRECI G
12	RRECIG	ARRO	S/C	(0,0,'A')	ERRECONERRECI GA
13	RECIGA	RROE	R	(6,1,'R')	ERRECONERRECI GARR
14	CIGARR	OERR	S/C	(0,0,'O')	ERRECONERRECI GARRO
15	IGARRO	ERRE	S/C	(0,0,'E')	ERRECONERRECI GARROE
16	GARROE	RREC	RR	(4,2,'E')	ERRECONERRECI GARROERRE
17	OERREC	CONE	S/C	(0,0,'C')	ERRECONERRECI GARROERREC
18	ERRECO	ONER	O	(1,1,'N')	ERRECONERRECI GARROERRECON
19	RRECON	ERRE	E	(4,1,'R')	ERRECONERRECI GARROERRECON ER
20	ECONER	REBA	R	(1,1,'E')	ERRECONERRECI GARROERRECON

					ERRE
21	ONERRE	BARR	S/C	(0,0,'B')	ERRECONERRECI GARROERRECON ERREB
22	NERREB	ARRI	S/C	(0,0,'A')	ERRECONERRECI GARROERRECON ERREBA
23	ERREBA	RRIL	RR	(5,2,'I')	ERRECONERRECI GARROERRECON ERREBARRI
24	EBARRI	L	S/C	(0,0,'L')	ERRECONERRECI GARROERRECON ERREBARRIL

b. Aplicar LZW usando como diccionario inicial los símbolos distintos de la cadena. Mostrar la evolución del diccionario, la secuencia de códigos emitidos y la descompresión.

índice	Símbolo
0	A
1	B
2	C
3	E
4	G
5	I
6	L
7	N
8	O
9	R

Paso	Cadena Acumulada	Evaluación (I + x)	Salida (Código Emitido)	Nueva entrada añadida al Diccionario
1	E	lee R (no se encuentra ER)	3	10=(ER)

2	R	lee R (no se encuentra RR)	9	11=RR
3	R	lee E (no se encuentra RE)	9	12=RE
4	E	lee C (no se encuentra EC)	3	13=EC
5	C	lee O (no se encuentra CO)	2	14=CO
6	O	lee N (no se encuentra ON)	8	15=ON
7	N	lee ER (no se encuentra NER)	7	16=NER
8	ER	lee RE (no se encuentra ERRE)	10	17=ERRE
9	RE	lee C (no se encuentra REC)	12	18=REC
10	C	lee I (no se encuentra CI)	2	19=CI
11	I	lee G (no se encuentra IG)	5	20=IG
12	G	lee A (no se encuentra GA)	4	21=GA
13	A	lee RR (no se encuentra ARR)	0	22=ARR
14	RR	lee O (no se encuentra RRO)	11	23=RRO
15	O	lee ERRE (no se encuentra OERRE)	8	24=OERRE
16	ERRE	lee CO (no se encuentra ERRECO)	17	25=ERRECO
17	CO	lee NER (no se encuentra CONER)	14	26=CONER

18	NER	lee RE (no se encuentra NERRE)	16	27=NERRE
19	RE	lee B (no se encuentra REB)	12	28=REB
20	B	lee ARR (no se encuentra BARR)	1	29=BARR
21	ARR	lee I (no se encuentra ARRI)	22	30=ARRI
22	I	lee L (no se encuentra IL)	5	31=IL
23	L	FIN	6	-

DESCOMPRESION

Cód. Recibido	Símbolo / Cadena	Nueva Entrada Reconstruida	Cadena Acumulada
3	E	—	E
9	R	10 = ER	ER
9	R	11 = RR	ERR
3	E	12 = RE	ERRE
2	C	13 = EC	ERREC
8	O	14 = CO	ERRECO

7	N	15 = ON	ERRECON
10	ER	16 = NER	ERRECONER
12	RE	17 = ERRE	ERRECONERRE
2	C	18 = REC	ERRECONERREC
5	I	19 = CI	ERRECONERRECI
4	G	20 = IG	ERRECONERRECIG
0	A	21 = GA	ERRECONERRECIGA
11	RR	22 = ARR	ERRECONERRECIGARR
8	O	23 = RRO	ERRECONERRECIGARRO
17	ERRE	24 = OERRE	ERRECONERRECIGARROERRE
14	CO	25 = ERRECO	ERRECONERRECIGARROERRECO
16	NER	26 = CONER	ERRECONERRECIGARROERRECONER
12	RE	27 = NERRE	ERRECONERRECIGARROERRECONER RE
1	B	28 = REB	ERRECONERRECIGARROERRECONER REB

22	ARR	29 = BARR	ERRECONERRECIGARROERRECONER REBARR
5	I	31 = ARRI	ERRECONERRECIGARROERRECONER REBARRI
6	L	32 = IL	ERRECONERRECIGARROERRECONER REBARRIL

c. Comparar qué tipo de repetición aprovecha cada método

criterio	LZ77	LZW
Estructura de Memoria	Ventana deslizante de tamaño fijo (6 de búsqueda + 4 de anticipación).	Diccionario dinámico global explícito sin ventana límite.
Tipo de Repetición Aprovechada	Redundancia Local / Cercana: Captura repeticiones dentro del rango corto de la ventana de búsqueda.	Redundancia Global / Frases Crecientes: Aprende frases completas (como ERRE) y las reutiliza sin importar la distancia.
Representación de Salida	Tuplas relativas (<i>offset, length, char</i>).	Índices numéricos directos apuntando al diccionario.

7. Codificación aritmética: Sea la fuente con $p(A)=0,50$; $p(B)=0,30$; $p(C)=0,20$ y la secuencia: ABACA

a. Codificar la secuencia mediante codificación aritmética. Mostrar los intervalos iniciales, las subdivisiones sucesivas y determinar el intervalo final. Elegir un valor perteneciente a dicho intervalo como representación de la secuencia.

Intervalos:

- Para A: [0.0 , 0.5) $Q_A = 0.0$ $R_A = 0.5$
- Para B: [0.5 , 0.8) $Q_B = 0.5$ $R_B = 0.8$
- Para C: [0.8 , 1) $Q_C = 0.8$ $R_C = 1$

Paso	Símbolo leído	Operación	Límite inferior	Límite superior	Amplitud o rango
------	---------------	-----------	-----------------	-----------------	------------------

Inicio	-	$U=0.0$ $V=1.0$	0.0	1.0	1.0
1	A	$U_{\text{nuevo}} = 0.0$ $V_{\text{nuevo}} = 0.5$	0.0	0.5	0.5
2	B	$U_{\text{nuevo}} = 0.25$ $V_{\text{nuevo}} = 0.4$	0.25	0.4	0.15
3	A	$U_{\text{nuevo}} = 0.25$ $V_{\text{nuevo}} = 0.325$	0.25	0.325	0.075
4	C	$U_{\text{nuevo}} = 0.31$ $V_{\text{nuevo}} = 0.325$	0.31	0.325	0.015
5	A	$U_{\text{nuevo}} = 0.31$ $V_{\text{nuevo}} = 0.3175$	0.31	0.3175	0.0075

El intervalo que identifica a ABACA es $[0.31, 0.3175)$.

$$0.31_{10} = 0.01001111_2$$

$$0.3175_{10} = 0.01010001_2$$

Buscando un binario intermedio encontramos 0.01010000_2 el cual representa el número 0.3125_{10}

El código binario final transmitido es 01010000

b. A partir del valor obtenido, realizar el proceso de decodificación y verificar que se recupera la secuencia original

Cadena que recibe el receptor 01010000, representa el 0.3125

Intervalos acumulados:

- A: $[0.0, 0.5)$
- B: $[0.5, 0.8)$
- C: $[0.8, 1)$

Paso	Valor a evaluar	Intervalo en el que cae	Símbolo decodificado	Operación de escalado para el siguiente paso
1	0.3125	$[0.0, 0.5)$	A	$0.3125 - 0.0 / 0.5 = 0.625$
2	0.625	$[0.5, 0.8)$	B	$0.625 - 0.5 / 0.3 = 0.417$
3	0.417	$[0.0, 0.5)$	A	$0.417 - 0.0 / 0.5 = 0.834$
4	0.834	$[0.8, 1)$	C	$0.834 - 0.8 / 0.2 = 0.17$


5	0.17	[0.0 , 0.5)	A	$0.17 - 0.0 / 0.5$ $= 0.34$
---	------	-------------	---	--------------------------------

FUENTES DE MARKOV

1. Dado el siguiente enunciado construir un conjunto de probabilidades condicionadas (con cuatro estados) en un proceso de Markov de primer orden, encontrar la matriz de transición y el grafo.

AABABACABABACABBABAACAB|AC

P(Yj/Xi)	A	B	C
A	2/13	7/13	4/13
B	7/8	1/8	0
C	1	0	0



2. A partir del ejercicio n°1
 - a. Obtener la matriz estacionaria (distribución a la que tiende).

Método analítico

$$P(S_j) = \sum_{i=1}^n P(S_i) \cdot P(S_j | S_i)$$

• Para A: $P(A) = P(A) \cdot P(A|A) + P(B) \cdot P(A|B) + P(C) \cdot P(A|C)$
 $P(A) = P(A) \cdot \frac{2}{13} + P(B) \cdot \frac{7}{8} + P(C) \cdot 1 \rightarrow \text{ec 1}$

• Para B: $P(B) = P(A) \cdot P(B|A) + P(B) \cdot P(B|B) + P(C) \cdot P(B|C)$
 $P(B) = P(A) \cdot \frac{7}{13} + P(B) \cdot \frac{1}{8} + P(C) \cdot 0 \rightarrow \text{ec 2}$

• Para C: $P(C) = P(A) \cdot P(C|A) + P(B) \cdot P(C|B) + P(C) \cdot P(C|C)$
 $P(C) = P(A) \cdot \frac{4}{13} + P(B) \cdot 0 + P(C) \cdot 0$

despejando

$$P(C) = \frac{4}{13} P(A)$$

$$P(B) = \frac{7}{13} P(A) + \frac{1}{8} P(B)$$

$$P(B) - \frac{1}{8} P(B) = \frac{7}{13} P(A)$$

$$\frac{7}{8} P(B) = \frac{7}{13} P(A)$$

$$P(B) = \frac{8}{13} P(A)$$

$$P(A) = \frac{2}{13} P(A) + \frac{7}{8} \cdot \frac{8}{13} P(A) + 1 \cdot \frac{4}{13} P(A) = 1$$

Condición de normalización:

$$\sum_{i=1}^3 P(S_i) = P(A) + P(B) + P(C) = 1$$

Sustituyendo:

$$\left(1 + \frac{8}{13} + \frac{4}{13} \right) P(A) = 1$$

$$\frac{25}{13} P(A) = 1$$

$$P(A) = \frac{13}{25} = 0,52$$

$$P(B) = \frac{8}{13} P(A) = \frac{8}{13} \cdot \frac{13}{25} = \frac{8}{25} = 0,32$$

$$P(C) = \frac{4}{13} P(A) = \frac{4}{13} \cdot \frac{13}{25} = \frac{4}{25} = 0,16$$

∴ la distribución estacionaria tiende a

$$\pi = [0,52; 0,32; 0,16]$$

b. Comprobar que las potencias sucesivas de la matriz de transición tienen menor variabilidad en los valores de sus componentes.

La celda P_{ij}^n indica la probabilidad de transición en n pasos. A medida que n aumenta, las filas de la matriz P^n reducen su diferencia y convergen hacia la distribución estacionaria π (perdiendo la memoria del estado inicial):

$$P^2 = \begin{pmatrix} 0.80235444 & 0.15010592 & 0.04730888 \\ 0.24395 & 0.486725 & 0.26915 \\ 0.1538 & 0.5384 & 0.3076 \end{pmatrix}$$

$$P^5 = \begin{pmatrix} 0.39027... & 0.39761... & 0.21152... \\ 0.64619... & 0.24390... & 0.10946... \\ 0.68766... & 0.21896... & 0.09291... \end{pmatrix}$$

$$P^{20} = \begin{pmatrix} 0.52152... & 0.31775... & 0.15858... \\ 0.51641... & 0.32090... & 0.16067... \\ 0.51556... & 0.32140... & 0.16100... \end{pmatrix}$$

por lo que seguir aumentando la potencia de la matriz resultara en la convergencia hacia la distribucion estacionaria

0.52 0.32 0.16

0.52 0.32 0.16

0.52 0.32 0.16

c. Comprobar que la distribución estacionaria es la misma para el cuadrado de la matriz de transición.

Por definición, una distribución π es estacionaria para una matriz de transición P si cumple la ecuación de equilibrio $\pi P = \pi$.

Para demostrar que esa misma distribución π sigue siendo la distribución estacionaria del cuadrado de la matriz (P^2), debemos verificar si satisface:

$$\pi P^2 = \pi$$

1. Descomponemos P^2 como el producto $P \cdot P$:

$$\pi P^2 = \pi(P \cdot P)$$

2. Aplicamos la propiedad asociativa del producto matricial:

$$\pi P^2 = (\pi P) \cdot P$$

3. Como sabemos por hipótesis que $\pi P = \pi$, reemplazamos el término entre paréntesis por π :

$$\pi P^2 = \pi \cdot P$$

4. Nuevamente, aplicando la propiedad estacionaria $\pi P = \pi$:

$$\pi P^2 = \pi$$

Conclusión: Queda demostrado de manera general que la distribución estacionaria para P^2 es exactamente la misma distribución π .

d. ¿Es un proceso ergódico?

Si, es un proceso Ergódico, ya que tras un número elevado de transiciones, alcanza el equilibrio estadístico. Cuando esto ocurre, la probabilidad de encontrar a la fuente en un estado determinado deja de variar con el tiempo y se vuelve totalmente independiente de la distribución inicial con la que arrancó el sistema.

3. Demostrar que las filas de la matriz de transición son linealmente dependientes en un proceso de Markov.

1. Propiedad Fundamental de la Matriz de Transición (P)

En un proceso de Markov de N estados, cada elemento $P_{ij} = P(S_j | S_i)$ representa la probabilidad condicional de pasar del estado S_i al estado S_j .

Como estando en un estado S_i el sistema debe transicionar obligatoriamente a alguno de los N estados posibles, la suma de los elementos de cada fila i es siempre igual a 1:

$$\sum_{j=1}^N P(s_j | s_i) = 1 \quad \forall i$$

2. Planteo del Sistema Estacionario

Para encontrar el vector de probabilidades estacionarias $\pi = [P(S_1), P(S_2), \dots, P(S_N)]$ se establece la ecuación de equilibrio algebraico:

$$P(S_j) = \sum_{i=1}^N P(S_i) \cdot P(S_j | S_i)$$

Expresado en forma matricial:

$$\pi P = \pi \iff \pi(P - I) = \mathbf{0} \quad \text{donde } I \text{ es la matriz identidad de dimensión } N \times N.$$

3. Demostración Matemática de la Dependencia Lineal

Queremos evaluar las propiedades de la matriz del sistema $M = (P - I)$. Multiplicamos M por el vector columna no nulo de unos

$$\mathbf{1} = \begin{bmatrix} 1 \\ 1 \\ \vdots \\ 1 \end{bmatrix} : \quad (P - I) \cdot \mathbf{1} = P\mathbf{1} - I\mathbf{1}$$

Si calculamos el i -ésimo componente del producto $P\mathbf{1}$:

$$(P\mathbf{1})_i = \sum_{j=1}^N P_{ij} \cdot 1 = 1$$

Por la propiedad estocástica de las filas, $P\mathbf{1} = \mathbf{1}$. Al reemplazarlo:

$$(P - I) \cdot \mathbf{1} = \mathbf{1} - \mathbf{1} = \mathbf{0}$$

Conclusión del Álgebra Lineal:

1. Al existir un vector no nulo $\mathbf{1} \neq \mathbf{0}$ tal que $(P - I)\mathbf{1} = \mathbf{0}$, el vector $\mathbf{1}$ pertenece al núcleo (espacio nulo) de la matriz $(P - I)$.
2. Esto demuestra que la matriz $(P - I)$ es singular (no invertible) y su determinante es estrictamente nulo: $\det(P - I) = 0$
3. Por definición, si el determinante de una matriz es cero, sus filas (y columnas) no son independientes; el rango de la matriz es como máximo $N - 1$. Por lo tanto, las filas de la matriz del sistema de transición $(P - I)$ son linealmente dependientes.

Debido a esta dependencia lineal, el sistema $\pi(P - I) = \mathbf{0}$ por sí solo tiene infinitas soluciones posibles. Por esta razón, para hallar la distribución estacionaria única, es

estrictamente obligatorio descartar una de las ecuaciones redundantes e introducir la condición de normalización de probabilidades:

$$\sum_{i=1}^N P(S_i) = 1$$

4. Analizar el siguiente ejemplo y responder los enunciados: Sea $S = (s_1, s_2, s_3, s_4)$ $p(s_i/s_{j1}, s_{j2}, s_{j3})$

a. ¿De qué orden es el sistema de Markov?

Es de **orden $m = 3$** , pues la probabilidad de emisión depende exclusivamente de los 3 símbolos inmediatamente anteriores (s_{j1}, s_{j2}, s_{j3})

b. ¿En cuántos estados puede encontrarse el sistema?

Para un alfabeto de $q = 4$ símbolos y orden $m = 3$, el número de estados posibles es:

$$|\Sigma| = q^m = 4^3 = 64 \text{ estados}$$

c. Supuestas conocidas todas las probabilidades condicionales ¿cuál será la forma del sistema de ecuaciones para encontrar las $p(s_i)$?

Cada estado σ_k se puede alcanzar desde otros estados mediante transiciones válidas. La probabilidad de estar en el estado σ_k es la suma de las probabilidades de estar en cualquier estado anterior σ_j , multiplicada por la probabilidad condicional de pasar de σ_j a σ_k :

$$P(\sigma_k) = \sum_{j=1}^{64} P(\sigma_j) \cdot P(\sigma_k | \sigma_j) \quad \text{para } k = 1, 2, \dots, 64$$

Dado que las filas de la matriz del sistema de ecuaciones son linealmente dependientes, el sistema lineal tiene infinitas soluciones. Para obtener la solución única, se descarta una ecuación redundante y se añade la regla de certeza:

$$\sum_{k=1}^{64} P(\sigma_k) = 1$$

Una vez obtenidas las probabilidades de los 64 estados $P(\sigma_k)$, la probabilidad marginal a priori de un símbolo individual s_i se obtiene sumando las probabilidades de todos los estados cuyo último símbolo emitido sea s_i de la siguiente forma:

Cada estado $\sigma_k = (x_1, x_2, x_3)$ está compuesto por una cadena de 3 símbolos. El último símbolo de esa cadena (x_3) representa el símbolo más reciente emitido por la fuente al llegar a dicho estado.

Los 64 estados se dividen en **4 grupos disjuntos de 16 estados cada uno**, según cuál sea el último símbolo x_3 de la cadena:

1. **Grupo Σ_{s_1}** : Los 16 estados que terminan en s_1 (ej.: (s_1, s_1, s_1) , (s_2, s_4, s_1) , etc.).
2. **Grupo Σ_{s_2}** : Los 16 estados que terminan en s_2 .
3. **Grupo Σ_{s_3}** : Los 16 estados que terminan en s_3 .
4. **Grupo Σ_{s_4}** : Los 16 estados que terminan en s_4 .

Suma de probabilidades de los estados que generan el símbolo: La probabilidad $P(s_i)$ de que la fuente emita el símbolo s_i es igual a la suma de las probabilidades estacionarias de todos los estados cuyo último símbolo sea s_i :

$$P(s_i) = \sum_{\sigma_k \in \Sigma_{s_i}} P(\sigma_k)$$

5. Supongamos una máquina con dos estados, anda=1, no anda=2. Estudiamos el proceso día a día llegando a comprobar que:
 - i. si anda hoy, hay un 75% de chances que ande mañana
 - ii. si no anda hoy, la arreglan mañana
 - a. Encontrar la matriz de transición
 - b. Calcular hasta la quinta potencia de la matriz de transición y analizar los resultados
 - c. Encontrar la matriz de equilibrio o estacionaria

a. Matriz de transición:

		1	2
P =	1	0.75	0.25
	2	1.00	0.00

Si funciona hoy (día 0) hay una probabilidad de 0.75 de que funcione en el día 1.
 Si funciona hoy (día 0) hay una probabilidad de 0.25 de que no funcione en el día 1.
 Si no funciona hoy (día 0) hay una probabilidad de 1 de que funcione en el día 1.
 Si no funciona hoy (día 0) hay una probabilidad de 0 de que funcione en el día 1.

b.

		1	2
P^2 =	1	0.8125	0.1875
	2	0.75	0.25

Si funciona hoy (día 0) hay una probabilidad de 0.8125 de que funcione en el día 2.
 Si funciona hoy (día 0) hay una probabilidad de 0.1875 de que no funcione en el día 2.
 Si no funciona hoy (día 0) hay una probabilidad de 0.75 de que funcione en el día 2.
 Si no funciona hoy (día 0) hay una probabilidad de 0.25 de que funcione en el día 2.

	1	2
P^3 = 1	0.796875	0.203125
2	0.8125	0.1875

Si funciona hoy (día 0) hay una probabilidad de 0.796875 de que funcione en el día 3.
 Si funciona hoy (día 0) hay una probabilidad de 0.203125 de que no funcione en el día 3.
 Si no funciona hoy (día 0) hay una probabilidad de 0.8125 de que funcione en el día 3.
 Si no funciona hoy (día 0) hay una probabilidad de 0.1875 de que funcione en el día 3.

	1	2
P^4 = 1	0.80078125	0.19921875
2	0.796875	0.203125

Si funciona hoy (día 0) hay una probabilidad de 0.80078125 de que funcione en el día 4.
 Si funciona hoy (día 0) hay una probabilidad de 0.19921875 de que no funcione en el día 4.
 Si no funciona hoy (día 0) hay una probabilidad de 0.796875 de que funcione en el día 4.
 Si no funciona hoy (día 0) hay una probabilidad de 0.203125 de que no funcione en el día 4.

	1	2
P^5 = 1	0.7998046875	0.2001953125
2	0.80078125	0.19921875

Si funciona hoy (día 0) hay una probabilidad de 0.7998046875 de que funcione en el día 5.
 Si funciona hoy (día 0) hay una probabilidad de 0.2001953125 de que no funcione en el día 5.
 Si no funciona hoy (día 0) hay una probabilidad de 0.80078125 de que funcione en el día 5.
 Si no funciona hoy (día 0) hay una probabilidad de 0.19921875 de que funcione en el día 5.

A medida que aumentamos las potencias (k), las filas comienzan a converger rápidamente hacia los mismos valores (c. matriz estacionaria) :

		1	2
$\lim_{k \rightarrow \infty} P^k \approx$	1	0.8	0.2
	2	0.8	0.2

Esto demuestra que, a mediano y largo plazo, el sistema "olvida" su estado inicial (si empezó andando o rota el día 0). La probabilidad de encontrar la máquina funcionando en cualquier día distante se estabiliza alrededor del 80%, y de encontrarla rota, del 20%.

6. Dado un proceso de Markov con tres estados a,b,c; con las siguientes probabilidades:
 $p(a/a)=3/4$; $p(c/c)=p(b/b)=1/2$; $p(b/a)=p(c/a)=1/8$; $p(a/b)=p(c/b)=p(a/c)=p(b/c)=1/4$
 comprobar que la longitud de Markov para un código compacto $LM = 11/8 < 12/8 = L$.

	a	b	c
a	3/4	1/8	1/8
P = b	1/4	1/2	1/4
c	1/4	1/4	1/2

La distribución estacionaria ($\pi = [P(a), P(b), P(c)] = [\pi_a, \pi_b, \pi_c]$) debe cumplir

$$\begin{aligned} - \pi_j &= \sum_{i=1}^n \pi_i \cdot P_{ij} \\ - \pi_a + \pi_b + \pi_c &= 1. \end{aligned}$$

columna a: $\frac{3}{4}\pi_a + \frac{1}{4}\pi_b + \frac{1}{4}\pi_c = \pi_a \Rightarrow \frac{1}{4}(\pi_b + \pi_c) = \frac{1}{4}\pi_a \Rightarrow \pi_b + \pi_c = \pi_a$

reemplazo: $\pi_a + \pi_a = 1 \Rightarrow 2\pi_a = 1 \Rightarrow \pi_a = 1/2$

columnas b y c: $1/2 + 2\pi_{b,c} = 1 \Rightarrow 2\pi_{b,c} = 1/2 \Rightarrow \pi_{b,c} = 1/4$.

Por lo tanto: $\pi_a = 1/2$; $\pi_b = \pi_c = 1/4$.

Por Huffman se le asigna por estado:

Para la fila a:

a con probabilidad 3/4 $\Rightarrow$ 1 bit

b con probabilidad 1/8 $\Rightarrow$ 2 bits

c con probabilidad 1/8 $\Rightarrow$ 2 bits

Longitud media del estado a:

$$L(S_a) = \left(\frac{3}{4} \cdot 1\right) + \left(\frac{1}{8} \cdot 2\right) + \left(\frac{1}{8} \cdot 2\right) = \frac{5}{4} \text{ bits/símbolo}$$

Para la fila b:

a con probabilidad 1/2 $\Rightarrow$ 1 bit

b con probabilidad 1/4 $\Rightarrow$ 2 bits

c con probabilidad 1/4 $\Rightarrow$ 2 bits

Longitud media del estado b:

$$L(S_b) = \left(\frac{1}{2} \cdot 1\right) + \left(\frac{1}{4} \cdot 2\right) + \left(\frac{1}{4} \cdot 2\right) = \frac{3}{2} \text{ bits/símbolo}$$

Para la fila c:

a con probabilidad 1/4 $\Rightarrow$ 2 bits

b con probabilidad 1/4 $\Rightarrow$ 2 bits

c con probabilidad 1/2 $\Rightarrow$ 1 bit

Longitud media del estado c:

$$L(S_c) = \left(\frac{1}{4} \cdot 2\right) + \left(\frac{1}{4} \cdot 2\right) + \left(\frac{1}{2} \cdot 1\right) = \frac{3}{2} \text{ bits/símbolo}$$

$$L_M = \pi_a \cdot L(S_a) + \pi_b \cdot L(S_b) + \pi_c \cdot L(S_c) \Rightarrow L_M = \frac{11}{8} \text{ bits/símbolo}$$

Para calcular L:

π_a con probabilidad 1/2 $\Rightarrow$ 1 bit

π_b con probabilidad $1/4 \Rightarrow 2$ bits

π_c con probabilidad $1/4 \Rightarrow 2$ bits

$$L = \left(\frac{1}{2} \cdot 1\right) + \left(\frac{1}{4} \cdot 2\right) + \left(\frac{1}{4} \cdot 2\right) = \frac{12}{8} \text{ bits/símbolo}$$

Por lo tanto, se comprueba que la longitud de Markov para un código compacto $LM = 11/8 < 12/8 = L$.

7. Usando el texto del ejercicio 6, Práctico No 3

- Codificar mediante los métodos: Huffman, Fano y Shannon como fuente de Markov de orden 1.
- Relevar para la fuente la estadística de primer orden y realizar una codificación predictiva.
- Realizar una transformación Burrows-Wheller y codificar mediante cuenta de símbolos iguales (RLE).
- Obtener los porcentajes de compresión y comparar los resultados obtenidos.

Texto: **ERRECONERRECIGARROERRECONERREBARRIL**

Longitud total (N): 35 caracteres.

Alfabeto ($q = 10$ símbolos distintos): S = A, B, C, E, G, I, L, N, O, R,

Frecuencias de primer orden (unigramas): R: 12, E: 8, C: 3, O: 3, A: 2, I: 2, N: 2, B: 1, G: 1, L: 1

- Codificación como fuente de Markov de orden 1 (Huffman, Fano y Shannon)

Matriz de probabilidades condicionales $P(S_{k+1}|S_k)$:

	A	B	C	E	G	I	L	N	O	R
A	0	0	0	0	0	0	0	0	0	1
B	1	0	0	0	0	0	0	0	0	0
C	0	0	0	0	0	1/3	0	0	2/3	0
E	0	1/8	3/8	0	0	0	0	0	0	4/8
G	1	0	0	0	0	0	0	0	0	0
I	0	0	0	0	1/2	0	1/2	0	0	0
N	0	0	0	1	0	0	0	0	0	0
O	0	0	0	1/3	0	0	0	2/3	0	0
R	0	0	0	1/3	0	1/12	0	0	1/12	1/2

Diccionarios de Codificación por Estado

- Estados determinísticos (A, B, G, N):** Al tener probabilidad 1.0, la transición está completamente determinada y requiere 0 **bits de información** (o 1 bit nulo '0' en la implementación paso a paso).
- Estado C ($O: 2/3, I: 1/3$):**
 - Huffman / Fano:** $O = 1, I = 0$ (1 bit c/u)
 - Shannon:** $O = 0, (1 \text{ bit}) I = 10$ (2 bits)

$$\log_2 \frac{1}{p_i} \leq l_i \leq \log_2 \frac{1}{p_i} + 1 \quad (1)$$

$$\begin{aligned} l_1 &= \log_2 \frac{1}{p_1} & l_2 &= \log_2 \frac{1}{p_2} \\ &= -\log_2 p_1 & &= -\log_2 p_2 \\ &= -\log_2 \frac{2}{3} & &= -\log_2 \frac{1}{3} \\ &= 0,58 \xrightarrow{\text{cu}} = 1 \text{ bit} & &= 1,58 \xrightarrow{\text{cu}} = 2 \text{ bits} \end{aligned}$$

s_i	$P(s_i)$	FA	Decimal	Binario	Long.	Código
s_1	$2/3$	0	0	0	1	0
s_2	$1/3$	$2/3$	0,66	0.10	2	10

3. Estado E ($R: 4/8, C: 3/8, B: 1/8$):

- **Huffman:** $R = 0$ (1 bit), $C = 10$ (2 bits), $B = 11$ (2 bits)

$$\begin{array}{lcl} R & 0 & 1/2 \rightarrow 1/2 \quad 0 \\ C & 10 & 3/8 \rightarrow 1/4 \quad 1 \\ B & 11 & 1/8 \rightarrow 1/4 \quad 1 \end{array}$$

- **Fano:** $R = 0$ (1 bit), $C = 10$ (2 bits), $B = 11$ (2 bits)

$$\begin{array}{lcl} \text{Cod} & S & \text{Prob.} \\ 0 & R & 1/2 \quad 0 \\ 10 & C & 3/8 \rightarrow 1/4 \quad 1 \\ 11 & B & 1/8 \rightarrow 1/4 \quad 1 \end{array}$$

- **Shannon:** $R = 0$ (1 bit), $C = 10$ (2 bits), $B = 111$ (3 bits)

$$\log_2 \frac{1}{p_i} \leq l_i \leq \log_2 \frac{1}{p_i} + 1 \quad (1)$$

$$\begin{aligned} l_1 &= \log_2 \frac{1}{p_1} & l_2 &= \log_2 \frac{1}{p_2} & l_3 &= \log_2 \frac{1}{p_3} \\ &= -\log_2 p_1 & &= -\log_2 p_2 & &= -\log_2 p_3 \\ &= -\log_2 \frac{4}{8} & &= -\log_2 \frac{3}{8} & &= -\log_2 \frac{1}{8} \\ &= 1 \text{ bit} & &= 1,41 \xrightarrow{\text{cu}} = 2 \text{ bits} & &= 3 \text{ bits} \end{aligned}$$

s_i	$P(s_i)$	FA	Decimal	Binario	Long.	Código
s_1	$4/8$	0	0	0	1	0
s_2	$3/8$	$4/8$	0,5	0.1	2	10
s_3	$1/8$	$7/8$	0,87	0.101	3	111

4. Estado I ($G: 1/2, L: 1/2$):


- **Huffman / Fano / Shannon:** $G = 0, L = 1$ (1 bit c/u)

5. Estado O ($N: 2/3, E: 1/3$) (idem Estado 2):


- **Huffman / Fano:** $N = 1, E = 0$ (1 bit c/u)
- **Shannon:** $N = 0$ (1 bit), $E = 10$ (2 bits)

6. Estado R ($R: 6/12, E: 4/12, O: 1/12, I: 1/12$):

- **Huffman:** $R = 0$ (1 bit), $E = 10$ (2 bits), $O = 110$ (3 bits), $I = 111$ (3 bits)



- **Fano:** $R = 0$ (1 bit), $E = 10$ (2 bits), $I = 110$ (3 bits), $O = 111$ (3 bits)



- **Shannon:** $R = 0$ (1 bit), $E = 10$ (2 bits), $I = 1101$ (4 bits), $O = 1110$ (4 bits)

$I_1 = -\log_2 1/p_1$ $I_2 = -\log_2 1/p_2$
 $= -\log_2 6/12$ $= -\log_2 4/12$
 $= 1 \text{ bit}$ $= 1,58 \xrightarrow{(")} 2 \text{ bits}$

$I_3 = I_4 = -\log_2 1/p_3$
 $= -\log_2 1/12$
 $= 3,58 \xrightarrow{(")} 4 \text{ bits}$

S_i	$P(s_i)$	FA	Decimal	Binario	Long.	Código
S_1	$6/12$	0	0	0	1	0
S_2	$4/12$	$6/12$	0,5	0.1	2	10
S_3	$1/12$	$10/12$	0,83	0.1101	4	1101
S_4	$1/12$	$11/12$	0,91	0.1110	4	1110

Cadenas codificadas:

HUFFMAN (50 bits): 00110010101100010100000011000010101100010110001111

FANO (50 bits): 00110010101100010100000011100010101100010110001101

SHANNON (55 bits): 0011001010000001010100000111010001010000001011100011011

Las cadenas comienzan con la codificación del símbolo E (0011). Este código se obtiene de la siguiente manera:

Dado que el alfabeto del texto consta de **10 símbolos distintos** ($q = 10$), la representación en código fijo de bloque requiere $-\log_2(1/p_i) \leq l_i \leq -\log_2(1/p_i) + 1$.

$$l_i = -\log_2(1/10) = 3,32 \rightarrow 4 \text{ bits}$$

Asignando a los 10 símbolos su índice binario de 4 bits en orden alfabético (del 0 al 9):

- **A** = 0000 (0)
- **B** = 0001 (1)
- **C** = 0010 (2)
- **E** = 0011 (3) ← **Código de cabecera para el estado inicial**
- **G** = 0100 (4)
- **I** = 0101 (5)
- **L** = 0110 (6)
- **N** = 0111 (7)
- **O** = 1000 (8)
- **R** = 1001 (9)

Para verificar paso a paso la construcción de la secuencia:


1. **E R R E**
 - Transiciones: $E \rightarrow R, R \rightarrow R, R \rightarrow E$
 - **Huffman / Fano:** $0 + 0 + 10 = \mathbf{0010}$
 - **Shannon:** $0 + 0 + 10 = \mathbf{0010}$
2. **C O N** (desde la E anterior)
 - Transiciones: $E \rightarrow C, C \rightarrow O, O \rightarrow N$
 - **Huffman / Fano:** $10 + 1 + 1 = \mathbf{1011}$
 - **Shannon:** $10 + 0 + 0 = \mathbf{1000}$
3. **E R R E** (desde la N anterior)
 - Transiciones: $N \rightarrow E, E \rightarrow R, R \rightarrow R, R \rightarrow E$
 - **Huffman / Fano:** $0 + 0 + 0 + 10 = \mathbf{00010}$
 - **Shannon:** $0 + 0 + 0 + 10 = \mathbf{00010}$
4. **C I G A R R O** (desde la E anterior)
 - Transiciones: $E \rightarrow C, C \rightarrow I, I \rightarrow G, G \rightarrow A, A \rightarrow R, R \rightarrow R, R \rightarrow O$
 - **Huffman:** $10 + 0 + 0 + 0 + 0 + 0 + 110 = \mathbf{1000000110}$
 - **Fano:** $10 + 0 + 0 + 0 + 0 + 0 + 111 = \mathbf{1000000111}$
 - **Shannon:** $10 + 10 + 0 + 0 + 0 + 0 + 1110 = \mathbf{101000001110}$
5. **E R R E** (desde la O anterior)
 - Transiciones: $O \rightarrow E, E \rightarrow R, R \rightarrow R, R \rightarrow E$
 - **Huffman / Fano:** $0 + 0 + 0 + 10 = \mathbf{00010}$
 - **Shannon:** $10 + 0 + 0 + 10 = \mathbf{100010}$
6. **C O N** (desde la E anterior)
 - Transiciones: $E \rightarrow C, C \rightarrow O, O \rightarrow N$
 - **Huffman / Fano:** $10 + 1 + 1 = \mathbf{1011}$

- **Shannon:** $10 + 0 + 0 = 1000$
- 7. **E R R E** (desde la N anterior)
 - Transiciones: $N \rightarrow E, E \rightarrow R, R \rightarrow R, R \rightarrow E$
 - **Huffman / Fano:** $0 + 0 + 0 + 10 = 00010$
 - **Shannon:** $0 + 0 + 0 + 10 = 00010$
- 8. **B A R R I L** (desde la E anterior)
 - Transiciones: $E \rightarrow B, B \rightarrow A, A \rightarrow R, R \rightarrow R, R \rightarrow I, I \rightarrow L$
 - **Huffman:** $11 + 0 + 0 + 0 + 111 + 1 = 110001111$
 - **Fano:** $11 + 0 + 0 + 0 + 110 + 1 = 110001101$
 - **Shannon:** $111 + 0 + 0 + 0 + 1101 + 1 = 11100011011$

b. Estadística de primer orden y codificación predictiva

1. **Estadística sin memoria:**

- **Entropía de la fuente:** $H(S) = -\sum P(S_i) \log_2 P(S_i) = 2.771 \text{ bits/símbolo.}$
- **Código Huffman de primer orden:**



- Longitud total del texto con Huffman sin memoria:
 $12(2) + 8(2) + 3(3) + 3(3) + 2(4) + 2(4) + 2(4) + 1(5) + 1(6) + 1(6) = 99 \text{ bits}$
- Longitud media $L_0 = \frac{99}{35} = 2.829 \text{ bits/símbolo}$

2. **Codificación Predictiva (DPCM):** Para cada símbolo actual S_k , se predice la salida más probable S_{k+1} :

- **Predicciones:**
 $A \rightarrow R; B \rightarrow A; C \rightarrow O; E \rightarrow R; G \rightarrow A; I \rightarrow G; N \rightarrow E; O \rightarrow N; R \rightarrow R$
- Tomamos de a pares de letras y comparamos la predicción con el real. Si se acierta se pone '1' si no se acierta un '0'
 - **Aciertos:** 21 de 34 (61.8% de eficacia de predicción).
 - **Fallos:** 13 de 34 (38.2%).

○ **Longitud total codificada:**

■ **Con símbolo de fallo en 4 bits:**

$$21 \times 1 \text{ bit} + 13 \times (1 \text{ flag bit} + 4 \text{ bits}) + 4_{\text{inicial}} = 90 \text{ bits (} \\ 2.571 \text{ bits/símbolo)}.$$

■ **Con símbolo de fallo en Huffman:**

$$21 \times 1 \text{ bit} + 13 \times 1 \text{ bit} + 41 \text{ bits}_{\text{Huffman}} = 75 \text{ bits (} \\ 2.143 \text{ bits/símbolo)}.$$

c. Transformación Burrows-Wheeler (BWT) y Run-Length Encoding (RLE)

Paso 1: Crear todas las rotaciones cíclicas:

$$\mathbf{M}_1 = \begin{pmatrix} R_0 \\ R_1 \\ R_2 \\ \vdots \\ R_{34} \end{pmatrix} = \begin{pmatrix} \text{ERRECONERRECIGARROERRECONERREBARRIL} \\ \text{RRECONERRECIGARROERRECONERREBARRILE} \\ \text{RECONERRECIGARROERRECONERREBARRILER} \\ \vdots \\ \text{LERRECONERRECIGARROERRECONERREBARRI} \end{pmatrix}$$

Paso 2: Ordenar las rotaciones lexicográficamente: Al ordenar alfabéticamente las 35 filas de la matriz $\mathbf{M}_1$, se obtiene la **matriz BWT ordenada** ($\mathbf{M}_2$). La primera columna se denomina F y la última columna se denomina L :

$$\mathbf{M}_2 = \begin{pmatrix} \mathbf{F} & \text{Cuerpo de la matriz} & \mathbf{L} \\ A & \text{ARRILERRECONERRECIGARROERRECONERRE} & B \\ A & \text{ARROERRECONERREBARRILERRECONERRECI} & G \\ B & \text{BARRILERRECONERRECIGARROERRECONERR} & E \\ \vdots & \vdots & \vdots \\ R & \text{RROERRECONERREBARRILERRECONERRECIG} & A \end{pmatrix}$$

Paso 3: Extraer la última columna, **Columna L (Salida BWT)**: Se extraen secuencialmente los caracteres de la última columna de la matriz $\mathbf{M}_2$:

$$L = BGEEEEERRRRNNOLICRIOORCCRRRRRREEEEAA$$

Resultado para la codificación RLE: Al aplicar RLE (Run-Length Encoding) sobre la columna L :

$$RLE(L) = 1B1G4E4R2N101L111C1R11201R2C6R4E2A$$

d. Porcentajes de compresión y comparación de resultados

A continuación se presenta la resolución completa y el análisis comparativo del **Punto D** (Porcentajes de compresión y comparación de resultados) tomando como base los datos de tu texto resuelto.

Tamaño de referencia (Sin Compresión)

Para medir el desempeño de cualquier algoritmo de compresión, tomamos como referencia la representación en código de longitud fija (ASCII / binario natural):

- Como el alfabeto tiene $q = 10$ símbolos distintos, cada carácter requiere 4 bits.
- Para los $N = 35$ caracteres de la cadena, el tamaño sin comprimir es:

$$\text{Tamaño Base} = 35 \text{ símbolos} \times 4 \text{ bits/símbolo} = 140 \text{ bits}$$

Porcentajes de Compresión por Método

El porcentaje de compresión C% se calcula como la reducción del tamaño respecto a los 140 bits originales:

$$C\% = \left(1 - \frac{\text{Bits Comprimidos}}{\text{Bits Originales}}\right) \times 100\%$$

1. Fuente de Markov de Orden 1 (Compresión considerando memoria previa)

- **Markov - Huffman:** 50 bits

$$C\% = \left(1 - \frac{50}{140}\right) \times 100\% = 64.29\%$$

- **Markov - Fano:** 50 bits

$$C\% = \left(1 - \frac{50}{140}\right) \times 100\% = 64.29\%$$

- **Markov - Shannon:** 55 bits

$$C\% = \left(1 - \frac{55}{140}\right) \times 100\% = 60.71\%$$

2. Estadística de Primer Orden y Codificación Predictiva

- **Huffman de Primer Orden (Sin Memoria):** 99 bits

$$C\% = \left(1 - \frac{99}{140}\right) \times 100\% = 29.29\%$$

- **Predictiva DPCM (Fallo en 4 bits fijos):** 90 bits

$$C\% = \left(1 - \frac{90}{140}\right) \times 100\% = 35.71\%$$

- **Predictiva DPCM (Fallo en Huffman):** 75 bits

$$C\% = \left(1 - \frac{75}{140}\right) \times 100\% = 46.43\%$$

3. BWT + RLE

- La salida de RLE agrupa repeticiones de la secuencia BWT: 1B 1G 4E 4R 2N 1O 1L 1I 1C 1R 1I 2O 1R 2C 6R 4E 2A.
- Esta secuencia tiene 17 corridas (pares contador + símbolo).
- Si codificamos cada contador en 3 bits (para representar números de 1 a 6) y cada símbolo en 4 bits (índice del alfabeto de 10 símbolos):

$$\text{Bits por Corrida} = 3 \text{ bits}(\text{contador}) + 4 \text{ bits}(\text{símbolo}) = 7 \text{ bits}$$

$$\text{Bits Total de} = 17 \text{ corridas} \times 7 \text{ bits} = 119 \text{ bits}$$

- **Porcentaje de compresión BWT + RLE:**

$$C\% = \left(1 - \frac{119}{140}\right) \times 100\% = 15.00\%$$

Tabla Comparativa

Método de Codificación	Modelo / Estrategia	Bits Totales	Longitud Media (L)	Compresión (C%)
------------------------	---------------------	--------------	--------------------	-----------------

Código Fijo Base	Sin memoria / Fijo	140 bits	4.000 bits/símb	0.00%
BWT + RLE	Reordenamiento + Conteo	119 bits	3.400 bits/símb	15.00%
Huffman Orden 0	Sin memoria / Frecuencia	99 bits	2.829 bits/símb	29.29%
DPCM (Fallo en 4 bits)	Predicción lineal $S_k \rightarrow \hat{S}_{k+1}$	90 bits	2.571 bits/símb	35.71%
DPCM (Fallo en Huffman)	Predicción + Adaptativo	75 bits	2.143 bits/símb	46.43%
Markov Order 1 - Shannon	Matriz condicional $P(S_{k+1} \parallel S_k)$	55 bits	1.571 bits/símb	60.71%
Markov Order 1 - Fano	Matriz condicional $P(S_{k+1} \parallel S_k)$	50 bits	1.429 bits/símb	64.29%
Markov Order 1 - Huffman	Matriz condicional $P(S_{k+1} \parallel S_k)$	50 bits	1.429 bits/símb	64.29%

Análisis Comparativo de Resultados

1. **Aprovechamiento de la memoria del texto:** La cadena presenta una marcada estructura condicional (por ejemplo, después de una N siempre viene una E, o de R suele venir otra R o E). Al modelar la fuente como una Cadena de Markov de orden 1, se logra el mejor rendimiento global (alcanzando hasta un 64.29% de compresión con Huffman y Fano). Esto se debe a que muchos estados son completamente determinísticos ($H(S_{k+1} \parallel S_k) = 0$).
2. **DPCM vs. Huffman sin memoria:** La codificación predictiva (DPCM) aprovecha la memoria de primer orden de forma parcial al acertar en el 61.8% de las transiciones. Esto permite superar ampliamente a Huffman sin memoria (reduciendo de 99 bits a 90 o 75 bits).
3. **Desempeño de BWT + RLE:** La transformada Burrows-Wheeler reordena la cadena agrupando caracteres similares (como las 6 R consecutivas o las 4 E). Sin embargo, la técnica de RLE por sí sola no es suficiente para lograr alta compresión en textos cortos (15% de compresión), ya que incluye muchas corridas de longitud 1 (ej: 1B, 1G, 1O). Para que BWT alcance su máximo potencial, suele ser necesario aplicar

Move-To-Front (MTF) seguido de un codificador entrópico (como Huffman o Arithmetic Coding) sobre la salida de BWT.